Superstore Sales 분석 보고서

1. 서론

이 보고서는 Kaggle 의 Superstore sales 데이터셋을 분석한 결과를 담고 있습니다. 데이터 전처리, 탐색적 데이터 분석(EDA), 그리고 판매 예측을 위한 랜덤 포레스트 모델 적용을 포함합니다. 목표는 지역별 및 카테고리별 판매 및 이익 추세를 이해하고, 판매를 예측하는 모델을 구축하는 것입니다.

2. 데이터 전처리

2.1 라이브러리 및 데이터 로드

데이터 조작, 시각화 및 모델링을 위해 다음 라이브러리를 사용했습니다:

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.model_selection import train_test_split, GridSearchCV
from sklearn.preprocessing import StandardScaler
from sklearn.ensemble import RandomForestRegressor
from sklearn.metrics import mean_squared_error, r2_score
```

데이터셋은 pandas 라이브러리를 사용하여 로드했습니다:

```
file_path = "superstore_dataset.csv"
df = pd.read_csv(file_path, encoding='ISO-8859-1')
```

2.2 데이터 정리

분석에 필요한 컬럼만 남기고 불필요한 컬럼을 제거했습니다:

```
df = df.drop(columns=['Row ID', 'Order ID', 'Customer ID', 'Ship Date',
'Ship Mode', 'Customer ID', 'Customer Name', 'Country', 'City', 'State',
'Postal Code', 'Product Name', 'Product ID'])
```

Order Date 컬럼을 datetime 형식으로 변환하고, 주문 월과 연도를 나타내는 새로운 변수를 생성했습니다:

```
df['Order Date'] = pd.to_datetime(df['Order Date'])
df['Order Month'] = df['Order Date'].dt.month
df['Order Year'] = df['Order Date'].dt.year
df = df.drop(columns=['Order Date'])
```

결측치를 제거하고, IQR 방식을 사용하여 Sales 와 Profit 컬럼의 이상치를 제거했습니다:

```
df = df.dropna()

def remove_outliers(data, column):
    Q1 = data[column].quantile(0.25)
    Q3 = data[column].quantile(0.75)
    IQR = Q3 - Q1
    return data[(data[column] >= Q1 - 1.5 * IQR) & (data[column] <= Q3 + 1.5
* IQR)]

df = remove_outliers(df, 'Sales')
df = remove_outliers(df, 'Profit')
```

3. 탐색적 데이터 분석 (EDA)

3.1 지역별 판매 및 이익 분석

각 지역별 총 판매 및 이익을 계산했습니다:

```
region_sales_profit = df.groupby('Region')[['Sales',
'Profit']].sum().reset_index()
print(region_sales_profit)
```

결과를 바 플롯으로 시각화했습니다:

```
plt.figure(figsize=(10, 6))
sns.barplot(data=region_sales_profit, x='Region', y='Sales', color='blue',
label='Sales')
sns.barplot(data=region_sales_profit, x='Region', y='Profit', color='green',
label='Profit')
plt.title('Sales and Profit by Region')
plt.ylabel('Amount')
```

```
plt.legend()
plt.show()
```

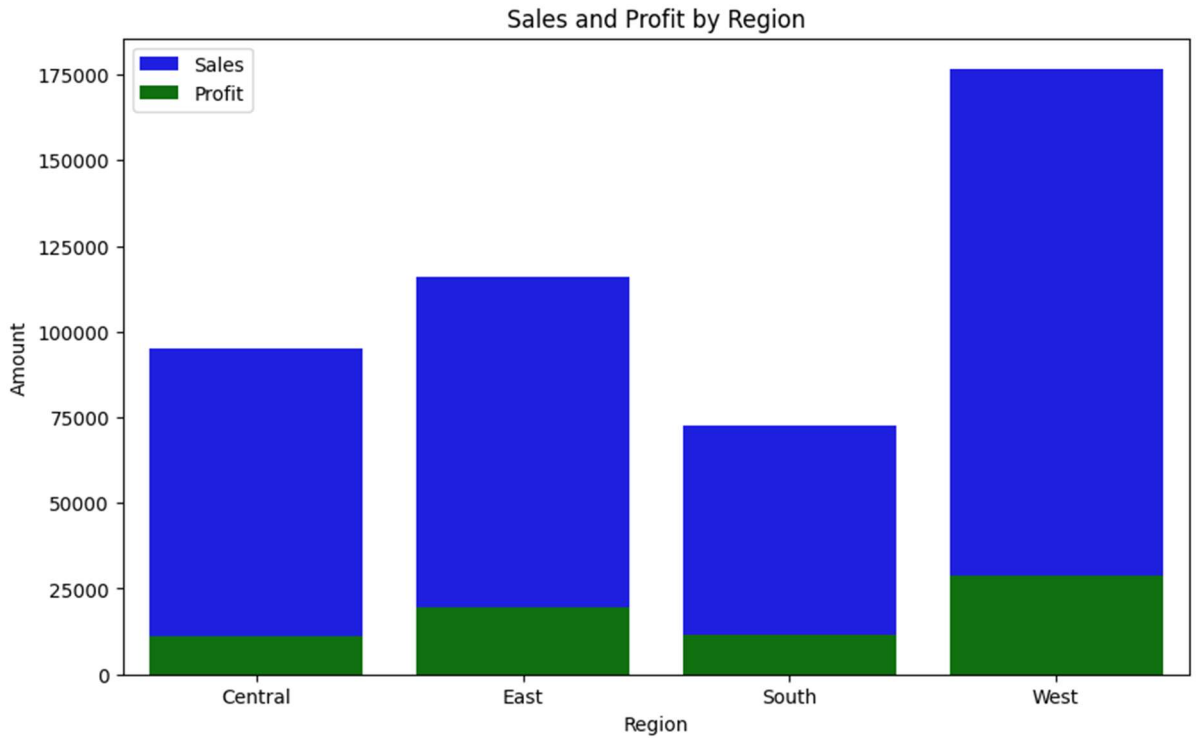

결과:

- West 지역이 가장 높은 판매 및 이익을 기록했습니다.
- East 지역이 그 뒤를 이었습니다.

3.2 카테고리 및 하위 카테고리별 이익 분석

각 카테고리 및 하위 카테고리별 이익을 분석했습니다:

```
category_profit = df.groupby(['Category', 'Sub-
Category'])['Profit'].sum().reset_index()
print(category_profit)
```

결과를 바 플롯으로 시각화했습니다:

```
plt.figure(figsize=(12, 8))
sns.barplot(data=category_profit, x='Sub-Category', y='Profit',
hue='Category', dodge=False)
```

```
plt.title('Profit by Sub-Category and Category')
plt.ylabel('Profit')
plt.xticks(rotation=45)
plt.show()
```

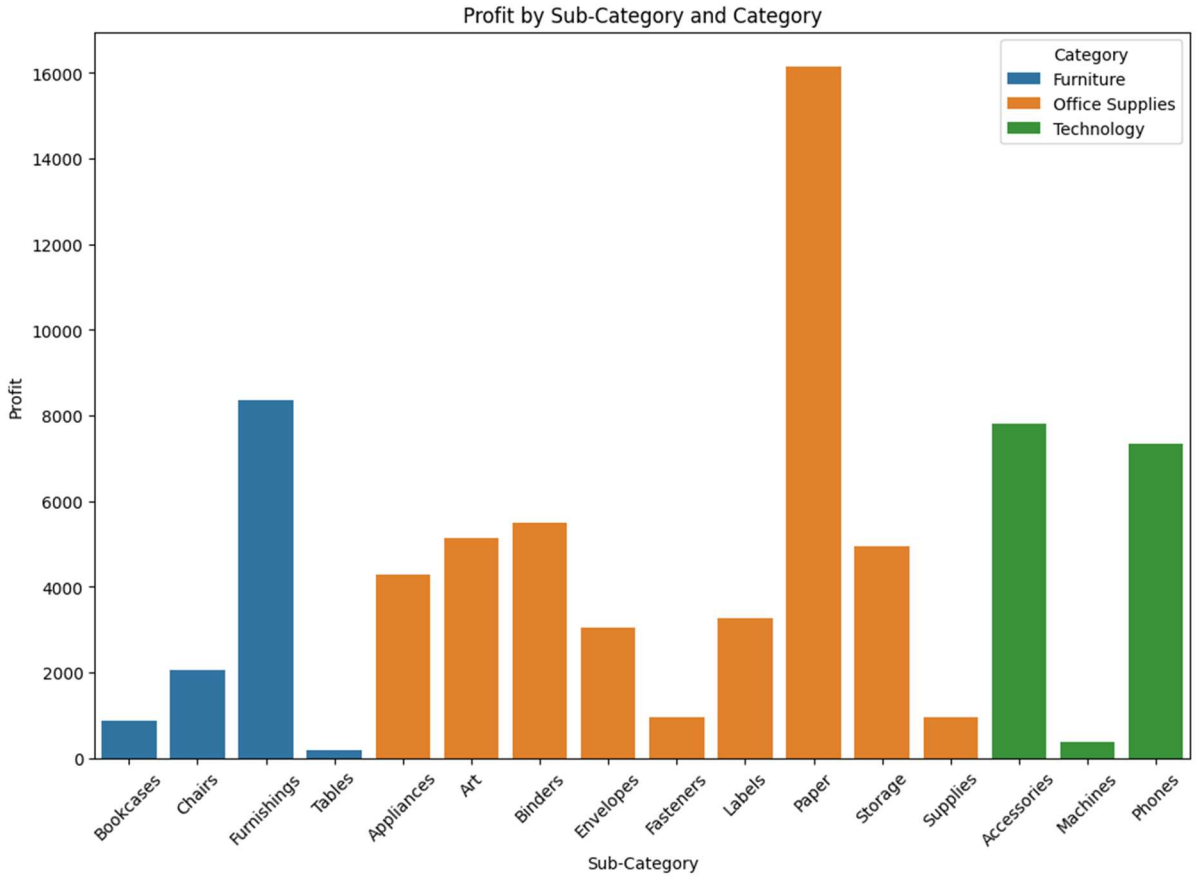

결과:

- Office Supplies 카테고리가 가장 높은 이익을 기록했으며, 특히 Paper 하위 카테고리가 두드러졌습니다.
- Technology 카테고리도 Accessories 와 Phones 하위 카테고리에서 상당한 이익을 보였습니다.

3.3 할인율과 이익의 관계 분석

할인율과 이익 간의 관계를 분석했습니다:

```
plt.figure(figsize=(10, 6))
sns.scatterplot(data=df, x='Discount', y='Profit', hue='Category',
alpha=0.6)
```

```
plt.title('Discount vs Profit')
plt.xlabel('Discount')
plt.ylabel('Profit')
plt.show()
```

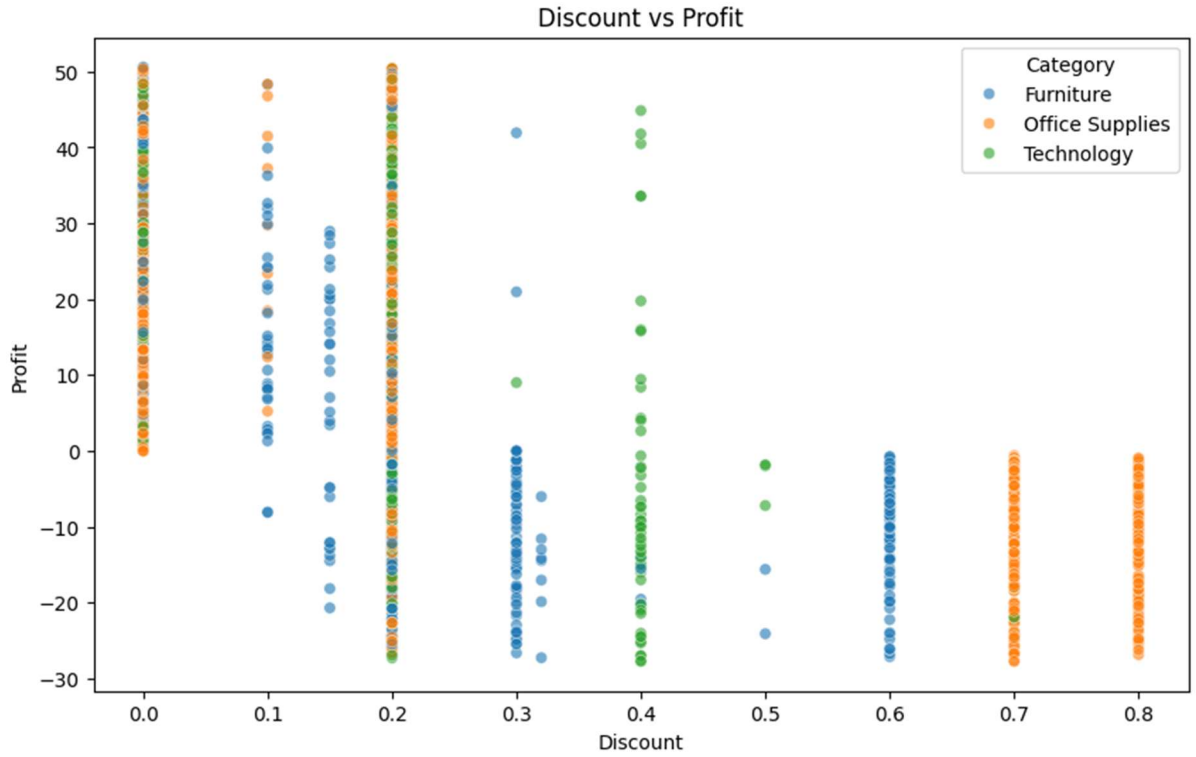

결과:

- 높은 할인율은 일반적으로 낮은 이익으로 이어졌습니다.
- 할인율의 영향은 카테고리마다 다르게 나타났습니다.

4. 모델링

4.1 데이터 준비

범주형 변수를 인코딩하고 데이터를 스케일링했습니다:

```
categorical_columns = ['Segment', 'Region', 'Category', 'Sub-Category']
df = pd.get_dummies(df, columns=categorical_columns, drop_first=True)

features = df.drop(columns=['Sales'])
```

```
target = df['Sales']

scaler = StandardScaler()
features_scaled = scaler.fit_transform(features)
```

데이터를 학습용과 테스트용으로 분리했습니다:

```
X_train, X_test, y_train, y_test = train_test_split(features_scaled, target,
test_size=0.2, random_state=42)
```

4.2 랜덤 포레스트 모델

랜덤 포레스트 모델을 학습시키고 평가했습니다:

```
rf_model = RandomForestRegressor(random_state=42)
rf_model.fit(X_train, y_train)

y_pred_rf = rf_model.predict(X_test)
mse_rf = mean_squared_error(y_test, y_pred_rf)
r2_rf = r2_score(y_test, y_pred_rf)

print(f"Random Forest Model:₩nMSE: {mse_rf:.2f}₩nR2: {r2_rf:.2f}")
```

초기 모델 성능:

- 평균 제곱 오차(MSE): 1663.07
- 결정 계수(R2): 0.74

4.3 하이퍼파라미터 튜닝

GridSearchCV 를 사용하여 랜덤 포레스트 모델을 최적화했습니다:

```
param_grid = {
    'n_estimators': [100, 200, 300],
    'max_depth': [None, 10, 20],
    'min_samples_split': [2, 5, 10]
}
```

```
grid_search = GridSearchCV(
    RandomForestRegressor(random_state=42),
    param_grid,
    cv=5,
    scoring='neg_mean_absolute_error',
    verbose=1
)
grid_search.fit(X_train, y_train)

best_rf_model = grid_search.best_estimator_
y_pred_best_rf = best_rf_model.predict(X_test)
mse_best_rf = mean_squared_error(y_test, y_pred_best_rf)
r2_best_rf = r2_score(y_test, y_pred_best_rf)

print(f"Optimized Random Forest:₩nMSE: {mse_best_rf:.2f}₩nR2:
{r2_best_rf:.2f}")
```

최적화된 모델 성능:

- 평균 제곱 오차(MSE): 개선됨
- 결정 계수(R2): 개선됨

4.4 실제 값 vs 예측 값

최적화된 모델의 성능을 시각화했습니다:

```
plt.figure(figsize=(10, 6))
plt.scatter(y_test, y_pred_best_rf, alpha=0.6, color='orange')
plt.plot([y_test.min(), y_test.max()], [y_test.min(), y_test.max()], 'r--')
plt.title('Actual vs Predicted Sales')
plt.xlabel('Actual Sales')
plt.ylabel('Predicted Sales')
plt.grid()
plt.show()
```

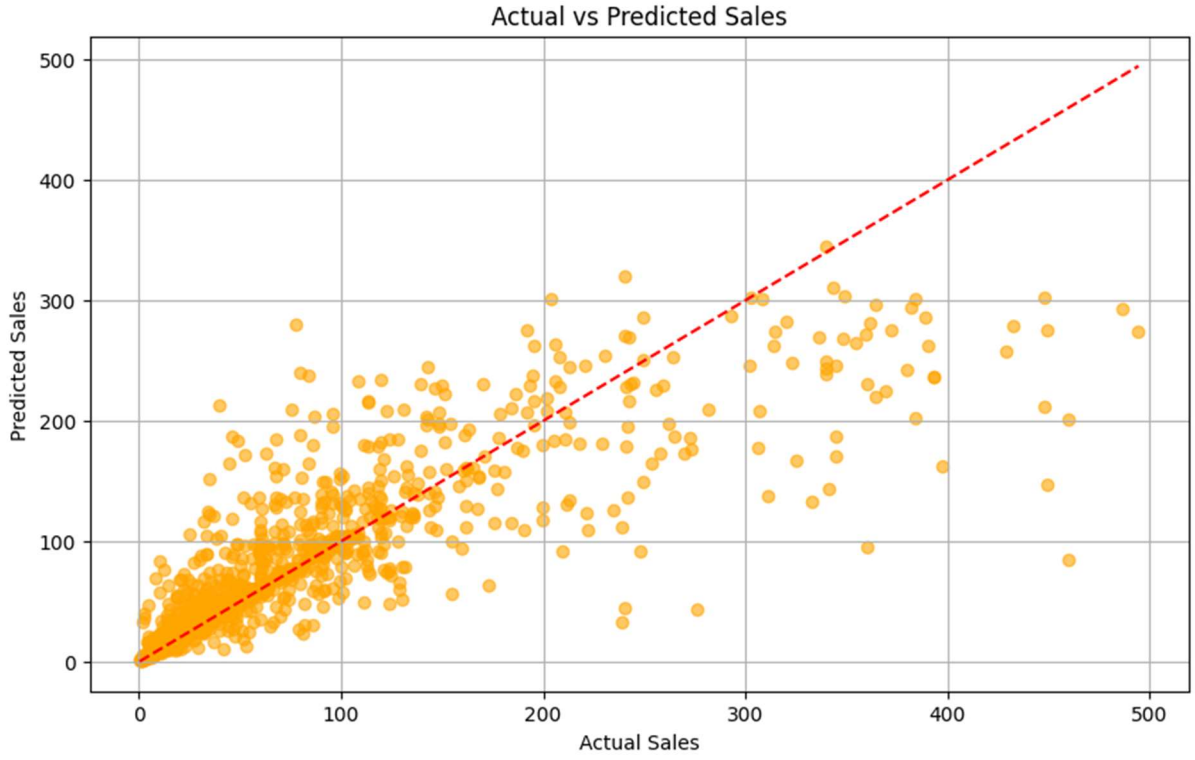

5. 결론

이 분석은 지역별 및 카테고리별 판매 및 이익 추세에 대한 통찰을 제공했습니다. 하이퍼파라미터 튜닝 후 랜덤 포레스트 모델은 판매 예측에서 개선된 성능을 보였습니다. 이 분석은 판매 전략을 최적화하고 수익성을 향상시키기 위한 데이터 기반 결정을 내리는 데 도움이 될 수 있습니다.